머신러닝 및 딥러닝 앙상블 모델을 활용한 피싱사이트 탐지 연구

WHS 2기 떡밥 팀 최종 발표

2024.07.14

떡밥 박찬민, 김주령, 김해찬, 김현진, 이경림, 이소영, 홍혜원

목차

01 프로젝트 개요
1. 팀원 소개
2. 프로젝트 배경
3. 프로젝트 소개
4. 프로젝트 진행 요약

02 프로젝트 수행
1. 데이터 수집
2. 피처 제작
3. AI 모델 개발

03 프로젝트 성과
1. 검증 데이터 추가 수집
2. 앙상블 모델 개발
3. 개발 결과 시각화

04 추후 계획
1. 앞으로의 계획

01 프로젝트 개요

1. 팀원 소개
2. 프로젝트 배경
3. 프로젝트 소개
4. 프로젝트 진행 요약

팀원 소개



멘토 손승호



PL 김두영



PM 박찬민



김주령



김현진



김해찬



이경림



이소영



홍혜원

프로젝트 배경



1. 피싱 사이트의 수법이 다양해지고 있음
2. 블랙리스트 방식으로 피싱 공격의 20%를 막지 못해 탐지가 어려움
3. 피해액이 조 단위를 넘어서고 있으며, 국가가 피싱 사이트 제작을 지원할만큼 규모가 커지고 있음
4. 개인 뿐만 아니라, 기업도 피해 대상이 됨

프로젝트 소개

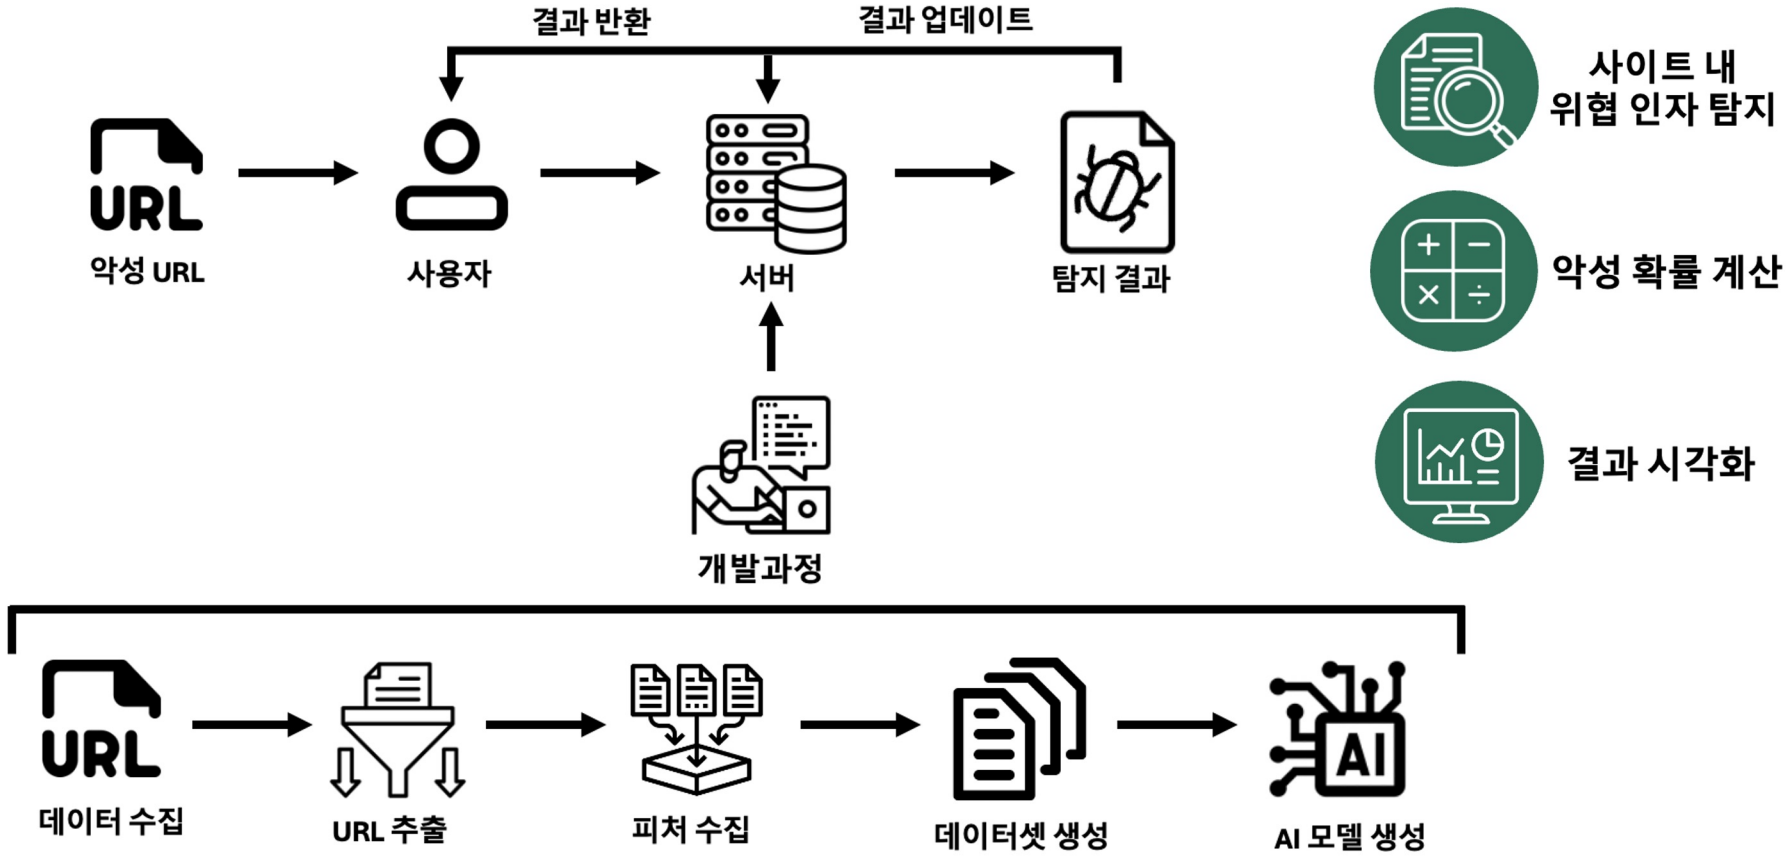
피싱사이트란?

- 정상 웹사이트를 가장한 사기 사이트
- 사용자를 속여 개인정보, 금융정보 등을 빼내는 것이 목적
- 외관이 거의 동일하게 만들어져 구분하기 어려움

피싱사이트 특징			
	• **URL 차이**: 정상 사이트와 유사한 URL을 사용하지만, 미묘한 차이가 있음 gabia.com'과 'gabiaing.com'은 비슷하지만 다른 URL을 사용	• **보안 인증서 차이**: 정상 사이트는 HTTPS 프로토콜을 사용하지만, 피싱 사이트는 HTTP만 사용하거나 유효하지 않은 인증서를 사용	• **콘텐츠 차이**: 피싱 사이트는 정상 사이트와 거의 동일한 콘텐츠를 가지고 있지만, 일부 차이가 있을 수 있음

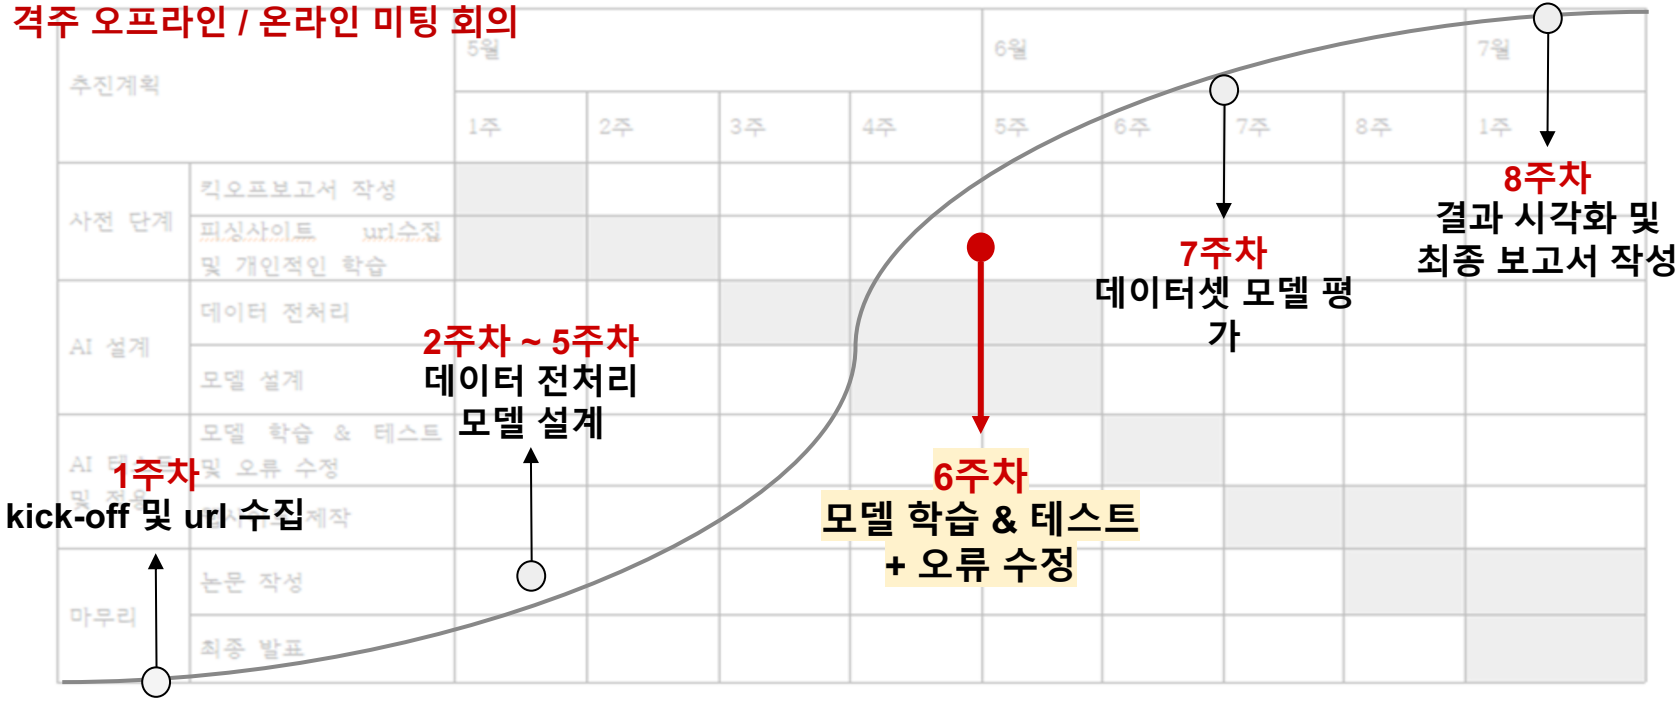
GOAL 이런 특징들을 **머신러닝 딥러닝 앙상블 모델**에 학습시켜 탐지하는 프로젝트

프로젝트 소개


결과 반환
결과 업데이트
URL
악성 URL
사용자
서버
탐지 결과
개발과정
사이트 내
위협 인자 탐지
악성 확률 계산
결과 시각화
URL
데이터 수집
URL 추출
피처 수집
데이터셋 생성
AI
AI 모델 생성

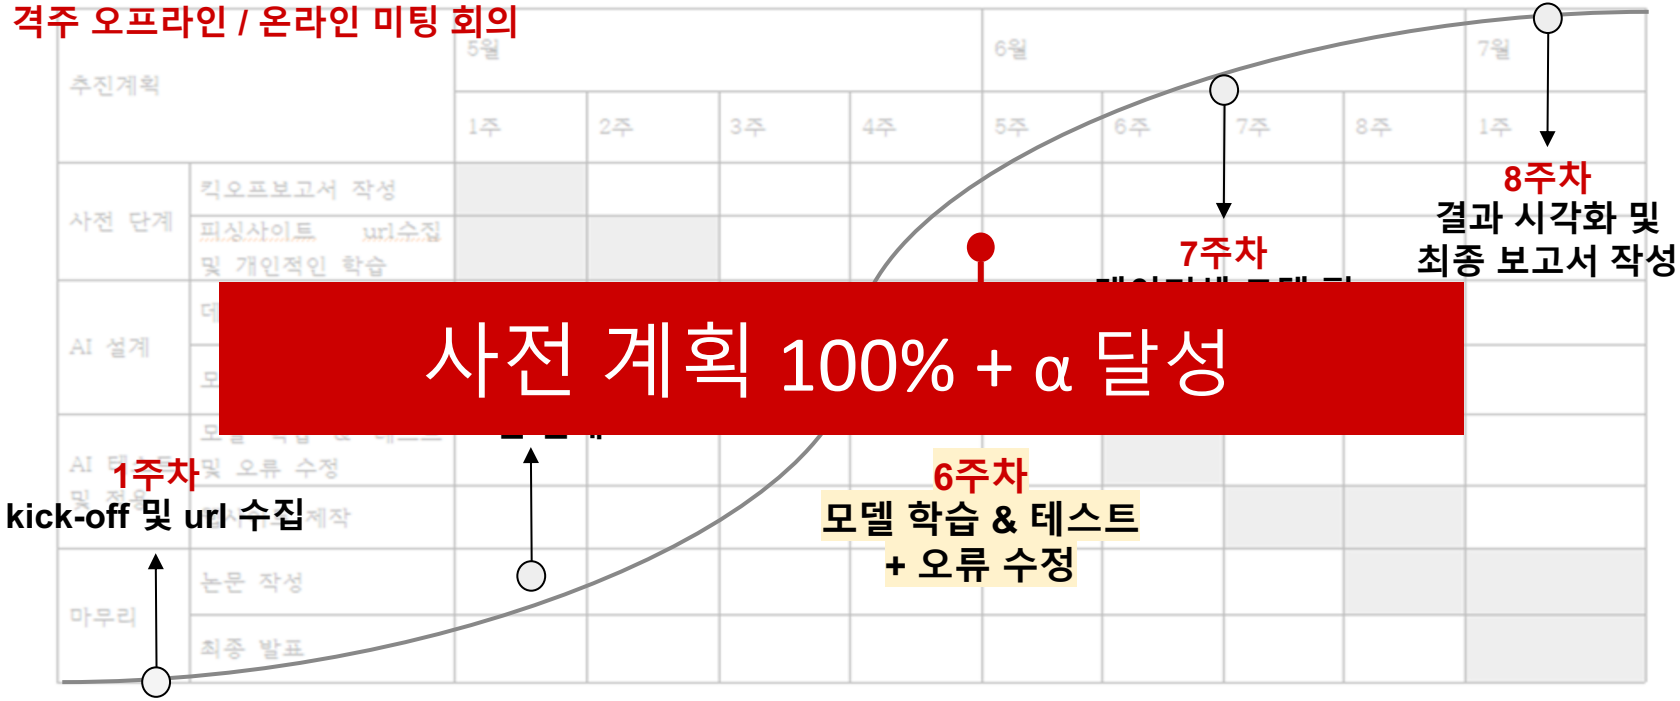
프로젝트 진행 요약

- 주 1회 온라인 멘토링 진행
- 격주 오프라인 / 온라인 미팅 회의



프로젝트 진행 요약

- 주 1회 온라인 멘토링 진행
- 격주 오프라인 / 온라인 미팅 회의



02 프로젝트 수행

1. 데이터 수집
2. 피쳐 제작
3. AI 모델 개발

데이터 수집

정상 URL

```
0          http://socialdisasterscommission.go.kr/
1             http://www.bai.go.kr/mobile/index.do
2                           http://www.bai.go.kr
3              http://www.bai.go.kr/child/index.do
4                           http://www.pasa.go.kr
                           ...
149995                   https://weekly-otter.com
149996                    https://alromansiah.com
149997                         https://araam.info
149998                      https://aramcalls.com
149999                        https://controlp.sa
Name: url, Length: 150000, dtype: object
```

정상 URL: 150000개

피싱 URL

```
0                  https://btinternet-106211.weeblysite.com/
1                  https://btinternet-107962.weeblysite.com/
2                  https://btinternet-109323.weeblysite.com/
3                       https://business-107847.square.site/
4                        https://home-101999.weeblysite.com/
                                ...
139989           https://tribelio.page/security1st-business
139990    https://docs.google.com/presentation/d/e/2PACX...
139991             https://alertadecuentas.webcindario.com/
139992    https://docs.google.com/presentation/d/e/2PACX...
139993             https://wbipprovincia13.webcindario.com/
Name: url, Length: 139994, dtype: object
```

피싱 URL: 139994개

피처 제작

URL 내에서 직접 얻을 수 있는 특성 수집

```
features['IP_LIKE'] = 1 if re.search(ip_pattern, url) else 0
features['AT'] = 1 if "@" in url else 0
features['URL_Depth'] = len([segment for segment in urlparse(url).path.split('/') if segment])
features['Redirection'] = 1 if url.rfind('//') > 6 else 0
features['Is_Https'] = 1 if urllib.parse.urlsplit(url).scheme == 'https' else 0
features['TINY_URL'] = 1 if re.search(shorteningServices, url) else 0
features['Query'] = len(parse_query_string(url))
features['(-)_InDomain'] = 1 if '-' in urlparse(url).netloc else 0
```

피처 제작

도메인 생성일, 도메인 만료일

```python
def is_domain_created(url):
    try:
        domain_name = urllib.parse.urlsplit(url).netloc
        socket.setdefaulttimeout(TIMEOUT)
        domain_info = whois.whois(domain_name)
        creation_date = domain_info.creation_date

        if isinstance(creation_date, list):
            creation_date = creation_date[0]

        if not creation_date or isinstance(creation_date, str):
            return 0  #
        two_years_ago = datetime.today() - timedelta(days=730)

        return -1 if creation_date <= two_years_ago else 0

    except (whois.parser.PywhoisError, socket.timeout, TypeError):
        return 0
```

```python
def get_domain_from_link(link):
    parsed_uri = urllib.parse.urlparse(link)
    return parsed_uri.netloc

def domain_end(domain_name):
    try:
        socket.setdefaulttimeout(TIMEOUT = 3)
        domain_info = whois.whois(domain_name)
        expiration_date = domain_info.expiration_date

        if isinstance(expiration_date, list):
            expiration_date = expiration_date[0]

        if expiration_date is None or isinstance(expiration_date, str):
            return 0

        days_until_expiry = (expiration_date - datetime.now()).days
        return -1 if (days_until_expiry / 30) >= 5 else 0

    except (whois.parser.PywhoisError, socket.timeout, ValueError, TypeError):
        return 0

def is_domain_created_within_six_months(url):
    domain_name = get_domain_from_link(url)
    return domain_end(domain_name)
```

피처 제작

마우스 오버 이벤트, 리디렉션, 하이퍼링크 개수

```python
def check_mouseover(html_content):
    soup = BeautifulSoup(html_content, 'html.parser')
    return 1 if soup.find(attrs={"onmouseover": True}) else 0

def check_url(url):
    try:
        response = requests.get(url, timeout=3)
        response.raise_for_status()
        return check_mouseover(response.text)
    except requests.exceptions.RequestException:
        return -1
```

```python
def count_hyperlinks(url):
    try:
        response = requests.get(url, timeout=TIMEOUT)
        response.raise_for_status()
        soup = BeautifulSoup(response.content, 'html.parser')
        return len(soup.find_all('a'))
    except (requests.RequestException, requests.Timeout):
        return -1
```

```python
def web_forwards(url, timeout=3):
    try:
        respon = requests.get(url, allow_redirects=True, timeout=timeout)
        if not respon.history or len(respon.history) <= 2:
            return 0
        return 1
    except requests.RequestException:
        return 1

def parallel_apply(urls, func, max_workers=5):
    results = []
    with ThreadPoolExecutor(max_workers=max_workers) as executor:
        future_to_url = {executor.submit(func, url): url for url in urls}
        for future in as_completed(future_to_url):
            try:
                results.append(future.result())
            except Exception:
                results.append(1)
    return results
```

피처 제작

도메인 일관성, 토큰화, 레이블

```python
def check_domain_consistency(url):
    try:
        response = requests.get(url, timeout=5)
        original_domain = urlparse(url).netloc
        final_domain = urlparse(response.url).netloc
        return 1 if original_domain == final_domain else 0
    except requests.RequestException:
        return -1
```

```python
features['Label'] = 0 #정상

features['Label'] = 1 #피싱
```

```python
def tokenize_url(url):
    tokens = []
    parsed_url = urlparse(url)

    # 도메인 토큰화
    domain_tokens = parsed_url.netloc.split('.')
    tokens.extend(domain_tokens)

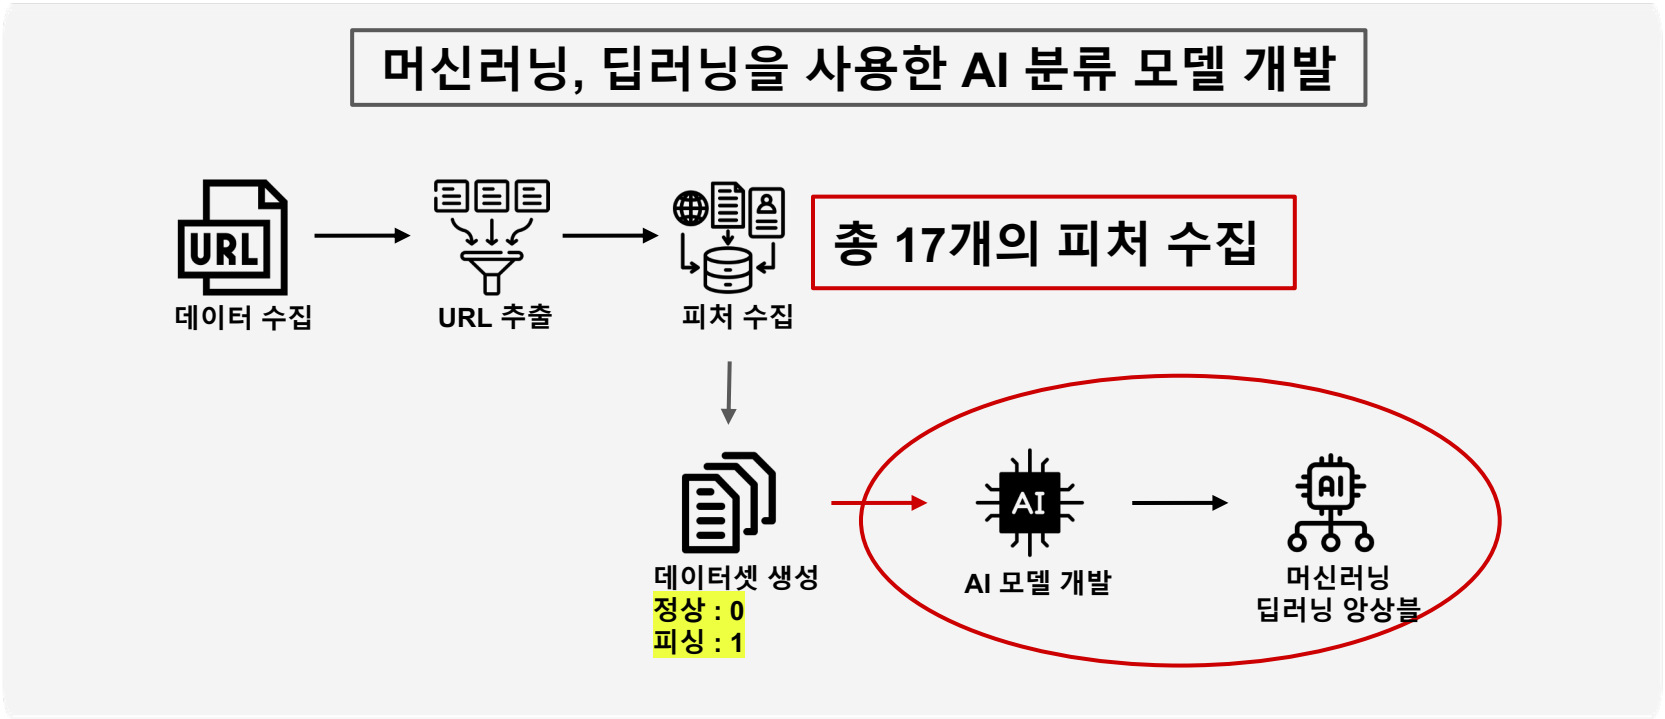
    # 경로 토큰화
    path_tokens = parsed_url.path.split('/')
    tokens.extend([token for token in path_tokens if token])

    # 쿼리 매개변수 토큰화
    query_tokens = parse_qs(parsed_url.query)
    for key, values in query_tokens.items():
        tokens.append(key)
        tokens.extend(values)

    return ' '.join(tokens)
```

AI 모델 개발

AI 모델 과정 모식도



AI 모델 개발

머신러닝 - LGBM

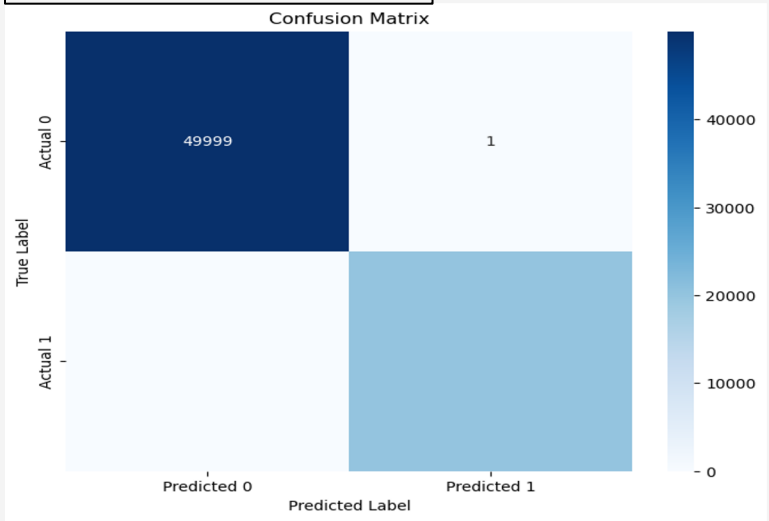
```
pipeline = Pipeline([
    ('scaler', StandardScaler(with_mean=False)),
    ('classifier', LGBMClassifier())
])
param_grid = {
    'classifier__num_leaves': [31, 63],
    'classifier__learning_rate': [0.01, 0.1],
    'classifier__n_estimators': [100, 200],
    'classifier__max_depth': [-1, 15, 30]
}
grid_search = GridSearchCV(pipeline, param_grid, cv=5, scoring='accuracy')

grid_search.fit(X_train, y_train)

best_params = {
    'learning_rate': 0.1,
    'max_depth': -1,
    'n_estimators': 100,
    'num_leaves': 31
}

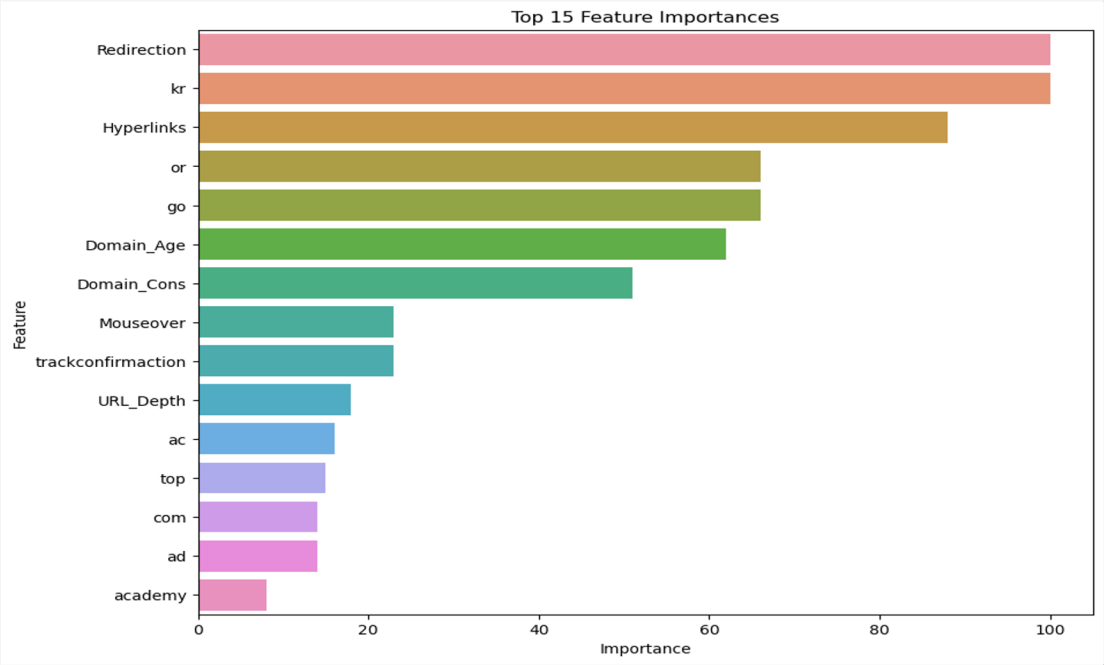
best_model = LGBMClassifier(**best_params)
best_model.fit(X_train, y_train)
```

train accuracy : 1.0



AI 모델 개발

LGBM - 피처 중요도



AI 모델 개발

딥러닝 - CNN

```
embedding_dim = 32
dropout_ratio = 0.3
num_filters = 32
kernel_size = 5

model = Sequential()
model.add(Embedding(vocab_size, embedding_dim))
model.add(Dropout(dropout_ratio))
model.add(Conv1D(num_filters, kernel_size, padding='valid', activation='relu'))
model.add(GlobalMaxPooling1D())
model.add(Dropout(dropout_ratio))
model.add(Dense(1, activation='sigmoid'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['acc'])

es = EarlyStopping(monitor='val_loss', mode='min', verbose=1, patience=3)
mc = ModelCheckpoint('best_model.keras', monitor = 'val_acc', mode='max', verbose=1, save_best_only=True)

history = model.fit(X_train_padded, y_train, epochs=10, batch_size=64, validation_split=0.2, callbacks=[es, mc])
```

train accuracy : 0.99

03 프로젝트 성과

1. 검증 데이터 추가 수집
2. 앙상블 모델 개발
3. 개발 결과 시각화

검증 데이터 추가 수집

정상 URL	피싱 URL

```
0          https://cazasolution.com
1          https://cedarandmoss.com
2            https://cfesuccess.com
3         https://cgitoronto.gov.in
4         https://chaletnicholas.ca
                    ...
49995               https://e-mis.kz
49996            https://e-oracle.ru
49997       https://earnbyvalue.com
49998          https://easy-code.ru
49999          https://easyspeak.ru
Name: url, Length: 50000, dtype: object
```

정상 URL: 50000개

```
0       https://allegrolokalnie.oferta-65492.pl/oferta...
1       https://pub-d0d0d5916dbd4da5b9fe7ed070e51dab.r...
2       https://anmeldung.client-eportal.is-certified....
3       http://malerbetrieb-steinin.blogdns.org/.kunde...
4       https://aktualisieren.83-229-87-162.cprapid.co...
                              ...
19995                              http://www.gwenet.org/
19996              http://files.planetaryedges.workers.dev
19997    https://docs.google.com/presentation/d/e/2PACX...
19998    https://docs.google.com/presentation/d/e/2PACX...
19999    https://docs.google.com/presentation/d/e/2PACX...
Name: url, Length: 20000, dtype: object
```

피싱 URL: 20000개

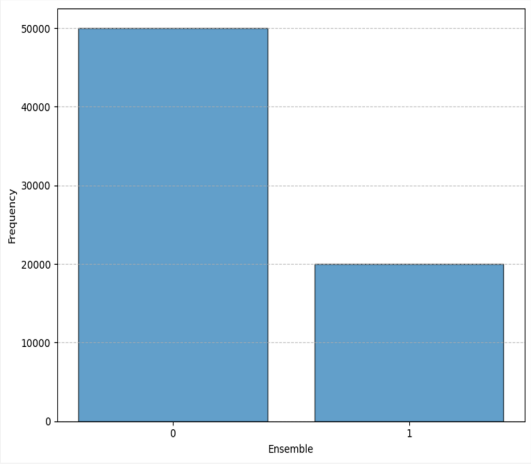
앙상블 모델 개발

검증 데이터 적용한 AI 모델별 결과 비교

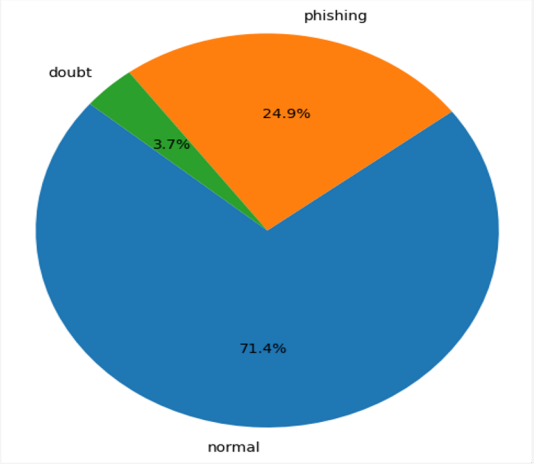
Model	Test set				Valid set			
	Accuracy	Precision	Recall	F1 Score	Accuracy	Precision	Recall	F1 Score
LightGBM	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
CNN	0.98	0.99	0.97	0.98	0.93	0.98	0.79	0.87
Ensemble (LGBM+CNN)	0.99	0.99	0.98	0.99	0.99	0.99	0.89	0.93

개발 결과 시각화

피싱 사이트 확률 계산(의심 범위 추가)



	실제값	LightGBM	CNN	앙상블	예측 확률	Label
0	0	0	0	0	[0.0077224243]	정상
1	1	1	0	1	[0.99999833]	피싱
2	0	0	0	0	[0.06402324]	정상
3	1	1	0	1	[1.0]	피싱
4	0	0	0	0	[0.027864434]	정상
...	...	...	...	...	...	...
69995	0	0	0	0	[0.06402324]	정상
69996	0	0	0	0	[0.0046846983]	정상
69997	0	0	0	0	[0.06402324]	정상
69998	0	0	0	0	[0.0060509653]	정상
69999	1	1	0	1	[1.0]	피싱



04 추후 계획

1. 앞으로의 계획

앞으로의 계획



웹 사이트 개발

대시보드로 디자인 한 UI를 기반으로
실제 이용할 수 있는 웹 사이트 개발 예정



공모전 및 대외활동 참가

2024년에 열리는
공모전 및 대외활동에 참가 예정



논문 게재

프로젝트 최종 발표 이후,
논문 게재 예정

마무리



떡밥팀의
발표를 들어주셔서
감사합니다!